Метка под вопросом

Пять агентов выбирают обращения, которым нужна ручная проверка.

Хримян Артур · Беседин Артем · Курилов Максим
Подылов Роман · Ковалев Илья

Каждый участник разрабатывает своего агента

Участник	Агент	Собственное решение
Ковалев Илья	Инструкция	Пересечения классов и уточнения
Беседин Артем	Семантика	Метка, цитата или воздержание
Подылов Роман	Согласованность	Значимость противоречий соседей
Хримян Артур	Арбитр	Рекомендация или повтор проверки
Курилов Максим	Очередь	Бюджет и пересмотр связанной группы

Общее состояние → решения агентов → человек → повторная проверка группы

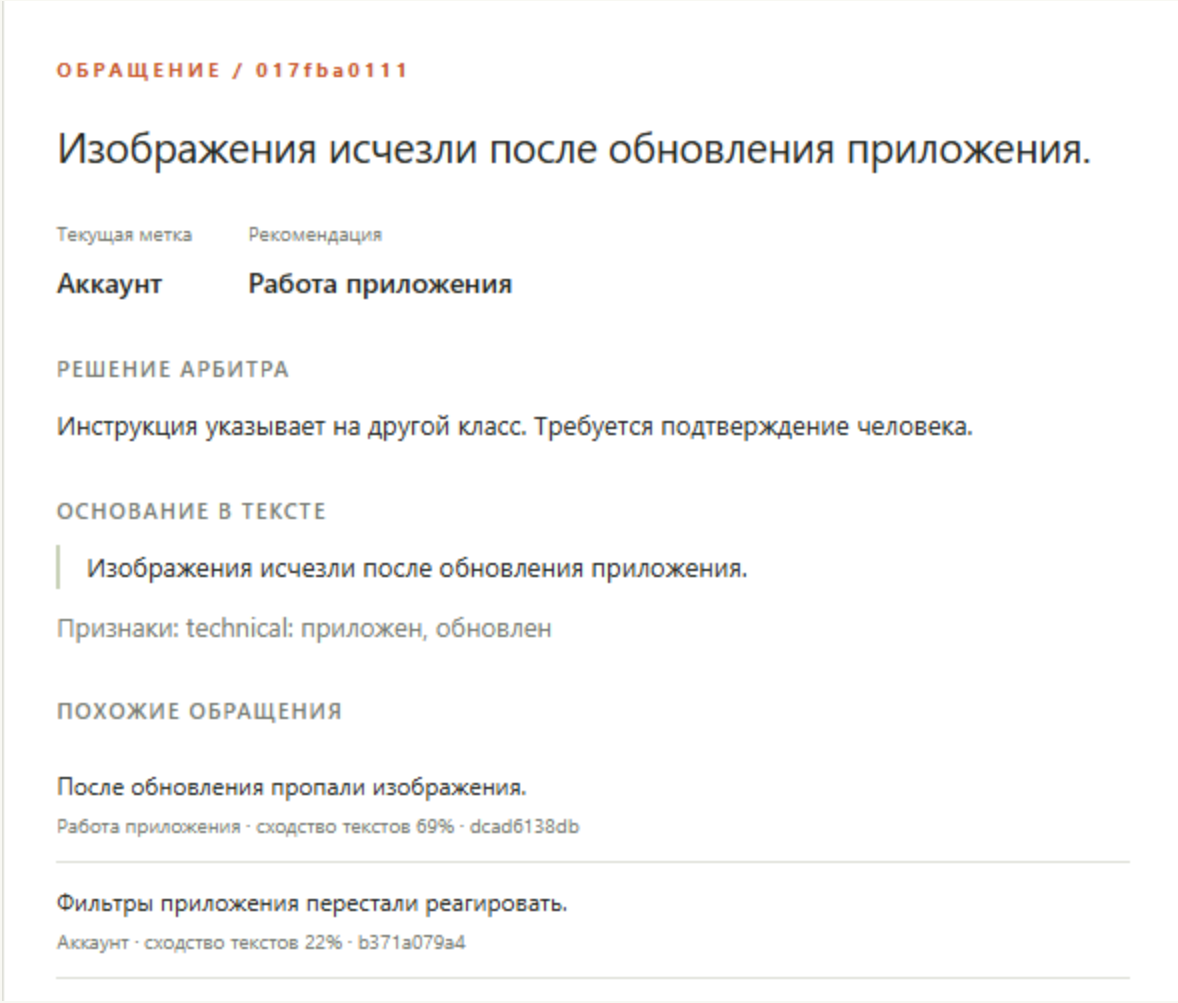
Рабочий сценарий проверки

CSV → очередь → решение человека

Цитата и похожие обращения помогают проверить рекомендацию.

После подтверждения агент очереди перепроверяет связанную группу.

Демо: 120 синтетических строк, эвристики, без вызовов LLM.



Первые результаты на синтетике

Ранжирование	Полезных / 20	Ошибок / 20
Случайно · среднее 100 seeds	7,46	4,11
Противоречия соседей	12	9
Ключевые слова	18	10
Пять агентов · demo	18	10

Ключевые слова и пять агентов дали одинаковый результат.

48 проверочных строк: 10 ошибок + 8 спорных. «Полезный» включает обе группы.
Это результаты эвристик на синтетике; качество LLM еще не измерено.

Смена темы и статус к КП2

План	Текущий статус
КП1: RAG по материалам, сканы, затем видео	Тема заменена аудитом разметки; прежний объем исключен
КП2: рабочий прототип и первые метрики	Пять модулей, интерфейс, очередь, экспорт, 29 тестов
LLM и проверка исследовательской гипотезы	Адаптер готов; живой прогон и реальные эталоны отсутствуют

Причина изменения: один тип данных и проверяемое качество очереди.

Согласование новой темы с преподавателем не подтверждено.

Следующие этапы до 15 декабря

19.11

Живая модель и 150 реальных обращений

Две независимые разметки; малый API-прогон, затем проверочная часть.

03.12

Сравнение при одинаковом бюджете

Один LLM, соседи, пять агентов; 300–500 строк и групповой split.

15.12

Закрытый тест и финальная защита

Качество, стоимость, демонстрация и подтвержденный вклад каждого.

Самооценка: инженерный прототип работает; польза LLM и пяти агентов требует проверки.

Резерв · Как читать метрики

18 / 20 = 0,90

Доля полезных случаев в очереди: ошибка или неоднозначность.

10 / 20 = 0,50

Доля действительно ошибочных меток в первых 20 строках.

Ограничения проверки

Синтетические эталоны без независимой ручной проверки.
Семейства парафраз разделены между dev и test.
Живой одиночный LLM baseline и стоимость пока не измерены.

Резерв · Границы готовности

Реализовано

Пять отдельных агентных модулей.
Ручная обратная связь и журнал.
Воспроизводимый эксперимент.
Код, данные и тесты в архиве.

Требует подтверждения

Живые ответы выбранной LLM.
Качество на реальных данных.
Личные изменения участников.
Согласование смены темы.

Каждый участник объясняет собственного агента.
Участник показывает конкретные изменения и результаты проверки.