КОМАНДНЫЙ ОТЧЕТ · КОНТРОЛЬНАЯ ТОЧКА 2

Метка под вопросом

Мультиагентная проверка качества текстовой разметки

Команда edinaya rossiya
Хримян Артур · Беседин Артем · Курилов Максим
Подылов Роман · Ковалев Илья

Дата: 5 ноября 2026 года. Новый проект выбран после КП1; прежняя тема поиска по учебным материалам не заявляется выполненной частью этой работы.

Проблема и аудитория

Ошибочные метки в обращениях клиентов ухудшают обучающий набор классификатора. Команда разметки тратит время на повторный просмотр всего CSV. Цель прототипа - выбрать наиболее полезные строки для ручной проверки и показать проверяемое основание рекомендации.

Пример: «Не могу войти после смены пароля» размечено как «Доставка». Система предлагает «Аккаунт» и показывает цитату. Сообщение сразу о доставке и оплате передается человеку без принудительного выбора одной метки.

Что предъявляется на КП2

Готово и проверено	Еще не подтверждено
Пять отдельных модулей агентов, локальный интерфейс, очередь, обратная связь, журнал и экспорт	Качество живой LLM и выигрыш пяти агентов на реальных данных
120 синтетических примеров, воспроизводимая оценка на 48 строках, 29 автоматических тестов	Независимая экспертная разметка, личные коммиты участников и согласование новой темы

Самооценка: работающий инженерный прототип с первыми проверяемыми результатами. Исследовательская часть и подтверждение индивидуального вклада остаются открытыми. Все опубликованные метрики относятся к эвристическому демо без LLM.

Пять агентов и общая архитектура

Каждый участник отвечает за собственного агента. Оркестратор связывает отдельные решения через общее состояние; агенты не являются пятью названиями одного запроса.

Владелец / агент	Решение и инструмент	Результат
Ковалев Илья Инструкция	Проверяет определения и пересечения; формирует вопросы к инструкции	Спецификация, версия, хеш, issues/questions
Беседин Артем Семантика	Сопоставляет текст с классами; выбирает один/несколько классов или воздержание	Метки, дословная цитата, запрос соседей
Подылов Роман Согласованность	Находит top-4 по символьному TF-IDF; проверяет значимость разных меток	Конфликт, ID соседей, обоснование
Хримян Артур Арбитр	Сопоставляет выводы; может вызвать один повтор семантической проверки	keep / change / review / recheck
Курилов Максим Очередь	Выбирает случаи при бюджете; после ответа человека выбирает связанную группу	Очередь, журнал решения, повторная проверка группы

Маршрут

CSV + инструкция → агент инструкции → семантика → согласованность и поиск соседей → арбитр → агент очереди → человек. После ответа человека повторно проверяется связанная группа; арбитр может вернуть отдельный случай на один пересмотр.

Стек и роль LLM

Python 3.10+, стандартная библиотека, локальный HTTP-интерфейс, JSON/CSV, символьный TF-IDF. Числа и метрики считает код. В режиме llm смысл и разногласия оценивает выбранная модель через совместимый Chat Completions API. В режиме demo те же контракты реализованы правилами.

Это фиксированный workflow с условными переходами. Общая модель в разных ролях может повторять одну ошибку. JSON, цитаты, ID, бюджет и число повторов проверяются программно. Полная схема и контракты находятся в docs/ARCHITECTURE.md.

План КП1 и фактический статус КП2

В КП1 был предложен RAG по учебным материалам, включая сканы и позднее аудио/видео. По решению пользователя новая тема - контроль разметки. Причина нового масштаба: один тип данных, отдельная роль каждого агента и объективно проверяемая очередь. Согласование смены темы с преподавателем не подтверждено.

Этап КП1	Изначальный результат	Статус в новом проекте
15.10	Корпус, парсеры, 100 вопросов	Заменен CSV обращений и инструкцией; выполнение старого этапа неизвестно
29.10	Первый RAG, текст и сканы	Исключен; вместо него проверка меток и доказательные фрагменты текста
05.11 / КП2	Рабочее демо и первые метрики	Есть автономное демо и синтетические метрики нового проекта
19.11	Пять агентов, аудио/видео	Пять модулей уже есть; срок отдан живой LLM и ручной разметке
03.12	300 вопросов, закрытый тест, baseline	Заменен набором обращений и сравнением способов отбора
15.12 / КП3	Финальная защита	Дата и требование воспроизводимости сохранены

Реализовано сейчас

Прием CSV и проверка схемы; пять агентных модулей; поиск соседей; арбитраж; приоритетная очередь; подтверждение человеком; повторная оценка группы; экспорт; промпты и API-адаптер; тесты и код оценки.

Отклонения и причины

Исходная предметная область заменена. Собственная модель не обучается. LangGraph, PostgreSQL и embeddings отложены: для КП2 достаточно малого локального набора. Живой LLM-прогон не выполнен из-за отсутствия настроенного доступа к модели; его результаты не подменены эвристическими.

Приведенные октябрьские даты - план из исходной презентации. Это не утверждение о датах выполнения новой реализации.

Данные и первые измерения

Набор содержит 120 созданных с помощью AI обращений: 100 однотемных и 20 спорных/непрофильных. В 24 однотемных примерах программно заменена метка. Seed: 20261105. Независимой экспертной проверки эталонов пока нет.

Разделение: 72 строки dev и 48 test, по семействам парафраз. В test: 10 внесенных ошибок, 8 спорных/непрофильных строк, 30 чистых. Это отдельная проверочная часть синтетического набора, а не независимый закрытый реальный тест.

Метод	Полезных из 20	Ошибок из 20	Recall ошибок в top-20
Случайная очередь[1]	7,46	4,11	0,411
Противоречия соседей	12	9	0,900
Ключевые слова	18	10	1,000
Пять агентов, demo	18	10	1,000

[1] Среднее по 100 перестановкам с seed 0–99. Для остальных методов порядок воспроизводим. Источник всех чисел: results/kp2_demo/metrics.json.

Определения метрик

Полезный случай - внесенная ошибка либо заранее выделенная неоднозначность/непрофильный текст. Precision@20 по полезным случаям = 18/20 = 0,90. Precision@20 именно по ошибкам = 10/20 = 0,50. Recall ошибок @20 = 10/10 = 1,00.

Доля предложенных изменений чистых меток: 0/30 в demo. Этот ноль на малом искусственном наборе не доказывает безопасность массового изменения. Изменения в исходник автоматически не вносятся.

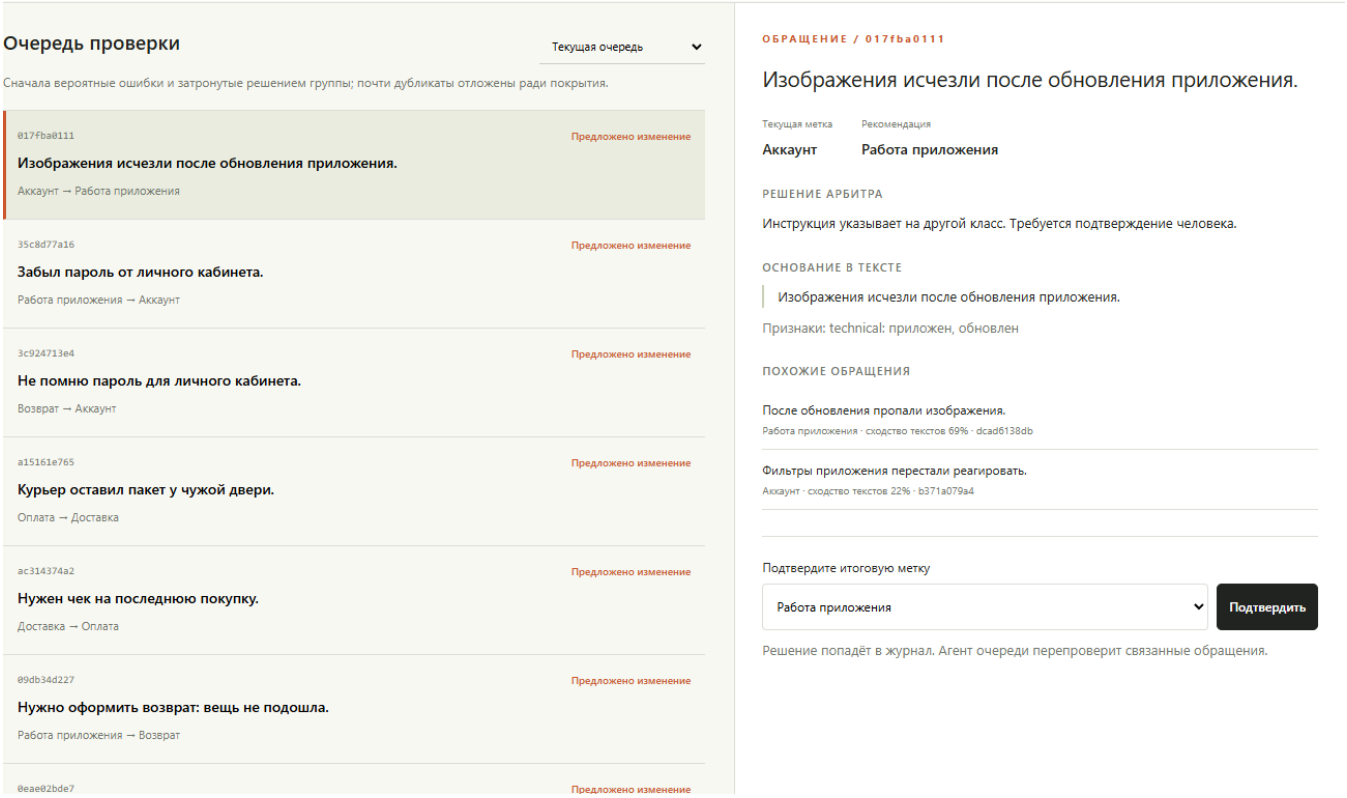
Вывод эксперимента

Пять агентов и ключевые слова дали одинаковый результат в top-20. Выигрыш мультиагентного подхода не доказан. Для следующего опыта нужны реальные расхождения разметчиков, отрицания, близкие классы и независимый одиночный LLM baseline при том же бюджете.

Эталоны находятся отдельно в evaluation/gold.json и читаются только оценщиком после завершения аудита. Вход агентов содержит лишь id, text, label и инструкцию.

Демонстрация и воспроизведение

Снимок ниже получен из работающего интерфейса на полном учебном наборе из 120 строк. Это демонстрационный запуск; численные метрики на предыдущей странице относятся к отдельным 48 проверочным строкам.



Сценарий

Загрузить CSV → запустить проверку → открыть строку → сопоставить цитату и соседей → подтвердить метку → увидеть новую очередь → выгрузить рекомендации или CSV с ручными исправлениями.

Команды из корня архива

```
python -m label_audit serve --open
python -m unittest discover -s tests -v
python -m label_audit evaluate --out runtime/evaluation
```

Достаточно Python 3.10+, зависимости для запуска приложения не устанавливаются. В Windows есть START_DEMO.bat и REPRODUCE.bat. Состояние каждого веб-запуска сохраняется в runtime/runs/; исходный CSV остается неизменным.

Для LLM задать LLM_BASE_URL, LLM_MODEL и при необходимости LLM_API_KEY. Сначала проверить 8 строк с лимитом 40 обращений. Полная инструкция находится в README.md; ключи в архив не включаются.

Проверки, стоимость и ограничения

Проверка	Фактический результат
29 автоматических тестов	Пройдены: пять агентов, формулы метрик, разделение данных, контракты, бюджет, кэш, HTTP и экспорт
Интерфейс в браузере	Проверены 120 строк, очередь на 20, подтверждение, обновление очереди и CSV; мобильный экран без горизонтального переполнения
LLM-адаптер	Проверен на локальном тестовом HTTP-сервере. Это не запуск и не оценка настоящей модели
Живая LLM	Не запускалась: ключ/API или локальная модель не настроены
Стоимость	В demo 0 API-вызовов. Для LLM стоимость неизвестна до прогона и ввода фактических тарифов

Лимиты и наблюдаемость

Не более 500 строк по 4000 символов. Дословность цитат, известность меток и ID, числовые границы confidence, бюджет очереди и максимум одного повторного разбора контролируются кодом. Временные сетевые ошибки допускают один повтор; каждая попытка расходует лимит обращений. При исчерпании лимита запуск прекращается с явной ошибкой.

Кэш привязан к endpoint, модели, промпту и данным. Токены берутся из usage провайдера. Если usage или тарифы отсутствуют, стоимость равна null. Повтор из кэша не считается новым API-запросом. Размер денежного бюджета не задается числом обращений.

Главные риски

Синтетика: простые ошибки завышают качество. **Общая модель:** агенты могут соглашаться в неверном выводе. **Поиск:** схожий текст может иметь другое намерение. **Инструкция:** пересечение классов нельзя исправить голосованием. **Стоимость:** несколько проверок могут не дать улучшения.

Известный трудный случай: «Доставка уже в порядке, проблема только с оплатой». Эвристика замечает две темы и отправляет строку человеку, хотя актуальное намерение одно. На подобных примерах требуется измерить реальную пользу LLM.

Ограничения локального прототипа: нет многопользовательской авторизации, промышленного развертывания и гарантии сохранения сессии в интерфейсе после перезапуска сервера. Файлы предыдущих запусков сохраняются. Публичный сервер не требуется условиями курса.

Индивидуальные зоны ответственности

Ключевое условие выполнено в структуре проекта: каждому закреплен собственный агент, вход, выход, решение, инструмент и тестируемый модуль. Инфраструктурные задачи не заменяют разработку агента.

Участник	Собственный модуль	Дополнительная часть
Ковалев Илья	agents/instruction.py InstructionAgent	Схема входа, таксономия, вопросы к инструкции
Беседин Артем	agents/semantic.py SemanticAgent	Промпт смысловой проверки, цитаты, интерфейс
Подылов Роман	agents/consistency.py ConsistencyAgent	retrieval.py, поиск соседей и противоречий
Хримян Артур	agents/arbiter.py ArbiterAgent	evaluation.py, эталоны, ложные исправления
Курилов Максим	agents/queue.py QueueAgent	Оркестрация, API, обратная связь, интеграция

Статус авторства

Распределение выше предложено для команды. Стартовый код и материалы подготовлены с помощью AI. История личных коммитов и уже выполненный каждым участником вклад не предоставлены; отчет не утверждает, что указанные люди лично написали весь закрепленный код.

Перед защитой каждому нужно запустить, изучить и доработать своего агента, показать тест и конкретное изменение. Доказательства вклада: коммит/PR или точный diff, пример до/после и результат проверки. Подробные индивидуальные задачи и вопросы к защите даны в docs/TEAM.md.

Аналоги и отличие задачи

Label Studio связывает разметку и ML-предсказания. cleanlab Datalab выявляет label issues, выбросы и близкие дубликаты. Наш узкий фокус - проверка русского текста по инструкции, явный арбитраж и очередь с ручной обратной связью. Отсутствие аналогов и превосходство над ними не заявляются.

Официальные источники: labelstud.io/guide/ml.html; docs.cleanlab.ai/stable/tutorials/datalab/text.html. Дата проверки: 05.11.2026. Подробные ссылки: docs/SOURCES.md.

План до финала и самооценка

Срок	Проверяемый результат	Владельцы
06–19.11	Живой API: сначала 8, затем 48 строк; 150 реальных обезличенных обращений с двумя независимыми разметками	Артем, Илья; все - перекрестная проверка
20.11–03.12	300–500 обращений; групповой split; отдельный одиночный LLM baseline, соседи и пять агентов	Роман, Артур; Максим - обратная связь
04–09.12	Разбор ошибок, стоимость на 100 строк, время, устойчивость; консультации по расписанию курса	Все участники
10–15.12	Заморозка промптов, закрытый тест, запись демо, итоговый отчет и подтвержденный личный вклад	Каждый за своего агента

Исследовательский вопрос

Позволяют ли инструкция, проверка соседей и арбитраж найти больше реальных ошибочных меток в первых 20 проверках, чем одиночный LLM, при сопоставимом расходе API? Плановый ориентир precision@20 по ошибкам ≥0,80 требует минимум 16 реальных ошибок в наборе и не переносится автоматически на текущую синтетику.

Самооценка на КП2

Инженерная часть: сквозной локальный сценарий работает, результаты воспроизводимы, роли разделены. **Оценка качества:** проведена только проверка на синтетике; преимущество над простым baseline не найдено. **Готовность к финалу:** нужны живые измерения, человеческие эталоны, подтвержденные личные доработки и согласование новой темы.

Комплект сдачи

Этот отчет; презентация с шестью основными и двумя резервными слайдами; архив исходников, данных, тестов и результатов; инструкция запуска; сценарий двухминутного выступления; снимки работающего интерфейса. Материалы не отправлялись преподавателю автоматически.

Источники требований

Присланная переписка курса: КП2 - отчет и презентация до 05.11, 12:00 МСК, выступление 2 минуты + 1 минута вопросов. Исходная дорожная карта - KP1_multiagent_updated(2).pptx. Новая тема и роли - переданный список тем и прямые уточнения пользователя. Полная трассировка требований находится в docs/REQUIREMENTS.md.

Технические источники: developers.openai.com/api/reference/resources/chat/subresources/completions/methods/create; docs.ollama.com/api/openai-compatibility. Конкретные модель, цены и качество не заявляются без фактического запуска.